

Note méthodologique : preuve de concept

Dataset retenu

Le dataset utilisé pour ce projet est intitulé **Truck Sales Dataset**, disponible publiquement sur Kaggle. Il contient les informations mensuelles sur les ventes de camions de janvier 2003 à décembre 2014.

- **Origine** : Dataset synthétique créé pour l'analyse de séries temporelles.
- **Caractéristiques** :
 - **Colonnes** : Month-Year (date au format "yy-MMM") et Number_Trucks_Sold (ventes mensuelles).
 - **Taille** : 144 échantillons.
 - **Période couverte** : 2003 à 2014.

Justification du choix : Le dataset présente plusieurs avantages pour notre analyse :


- **Simplicité et propreté des données** : Aucune valeur manquante ni anomalie détectée, garantissant une compatibilité immédiate avec les modèles.
- **Diversité temporelle** : La période de 12 ans permet d'observer des tendances, des cycles saisonniers et des variations interannuelles.
- **Complexité modérée** : Idéal pour comparer des modèles tels qu'ARIMA et Chronos tout en garantissant des résultats exploitables.
- **Nature synthétique** : Évite les biais dus à des événements externes imprévisibles, tout en restant représentatif des séries temporelles réelles.

Cependant, ce dataset présente une limite : il n'inclut pas de variables explicatives (comme les données économiques), qui pourraient enrichir les prévisions et augmenter leur précision.

Les concepts de l'algorithme récent

Chronos est une suite d'algorithmes d'Amazon Science développée pour la prédiction de séries temporelles. Elle repose sur l'architecture T5 (Text-To-Text Transfer Transformer), adaptée pour manipuler des données séquentielles et générer des prévisions robustes.

Principe de fonctionnement



Tokenisation des séries temporelles

Le modèle commence par transformer les séries temporelles en une séquence de tokens compréhensibles pour un modèle de langage.

- **Scaling et quantification :** Chaque point temporel est normalisé (échelle moyenne) et converti en token numérique via un processus de quantification.
- **Contexte temporel :** Ces tokens capturent les relations entre les événements passés et servent d'entrée au modèle.

Entraînement du modèle

- **Modèle préentraîné :** Chronos s'appuie sur des modèles de type encoder-decoder ou decoder-only, comme T5, préentraînés sur de larges ensembles de données synthétiques et réelles.
- **Optimisation :** L'apprentissage est réalisé en minimisant la cross-entropy, une fonction de perte adaptée à la prédiction probabiliste. Cela permet au modèle de générer des distributions prédictives fiables.

Génération de prédictions

- **Échantillonnage probabiliste :** Lors de l'inférence, le modèle génère des tokens de manière autorégressive (un à la fois) et les mappe en valeurs numériques.
- **Prédictions multiples :** Plusieurs trajectoires sont échantillonnées pour produire une distribution prédictive complète, offrant des intervalles de confiance autour des prévisions centrales.

Innovations majeures

- **Prévisions probabilistes** : Chronos génère des intervalles de confiance en plus des valeurs prédictives centrales, ce qui permet de quantifier l'incertitude.
- **Flexibilité adaptative** : Il peut traiter des données avec différents horizons temporels (jour, mois) et s'adapte à divers scénarios industriels.
- **Entraînement efficace** : Les modèles préentraînés réduisent les besoins en calcul et accélèrent le déploiement.
- **Applications multi-domaines** : Chronos excelle dans des domaines variés (finance, logistique, santé) en offrant une précision accrue pour des cas complexes.

Avantages par rapport à ARIMA

- **Gestion des non-stationnarités** : Contrairement à ARIMA, il n'exige pas de différenciation manuelle des données.
- **Prédictions multidimensionnelles** : Chronos peut gérer plusieurs variables exogènes et prédire simultanément plusieurs séries.
- **Robustesse** : Il est performant sur des séries complexes présentant des fluctuations irrégulières.
- **Précisions probabilistes** : En fournissant des intervalles d'incertitude, il améliore la prise de décision stratégique.

Conclusion

Chronos est une évolution majeure dans la prédiction de séries temporelles. Sa combinaison d'une architecture transférable, de prédictions probabilistes et de flexibilité à différents cas d'usage le positionne comme une alternative puissante aux modèles traditionnels comme ARIMA. Avec ses avancées technologiques, il offre une solution fiable et précise pour les prévisions complexes.

La modélisation

Ce chapitre décrit la méthodologie de modélisation mise en œuvre dans ce projet, en mettant l'accent sur l'utilisation des modèles ARIMA et Chronos, ainsi que leur comparaison grâce à AutoGluon.

Méthodologie de modélisation

Formulation mathématique d'ARIMA

L'ARIMA (p,d,q) modélise une série temporelle Y_t par une combinaison linéaire de ses valeurs passées et d'un bruit blanc :

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \sum_{j=1}^q \theta_j \varepsilon_{t-j} + \varepsilon_t$$

Dans notre cas, ARIMA(5,1,1) a été sélectionné automatiquement, signifiant que le modèle prend en compte 5 valeurs passées avec une différenciation d'ordre 1.

Lien avec ce projet

ARIMA(5,1,1) a été sélectionné avec auto_arima en minimisant l'AIC. Il capture les tendances et saisonnalités sans prétraitement manuel.

Interprétabilité du modèle ARIMA

ARIMA est un modèle très interprétable, car chaque composant (autorégressif, différenciation, moyenne mobile) a une signification claire. Les coefficients du modèle indiquent l'importance des valeurs passées sur la prédiction.

De plus, l'analyse des résidus permet d'évaluer si les hypothèses du modèle sont respectées (stationnarité, bruit blanc). Cela permet d'expliquer les décisions du modèle et d'ajuster ses paramètres si nécessaire.

Modélisation avec Chronos

Formulation mathématique de Chronos

Chronos utilise une architecture transformer inspirée des modèles NLP. Il encode les séries temporelles sous forme de séquences et applique des opérations de pondération pour capter les relations entre points temporels.

$$Z = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V$$

Il génère des prédictions probabilistes en intégrant l'incertitude via des distributions d'échantillonnage.

Interprétabilité du modèle Chronos

Contrairement à ARIMA, Chronos est basé sur un réseau de neurones transformeur, ce qui le rend plus difficile à interpréter directement. Toutefois, son mécanisme d'attention permet d'identifier quelles périodes passées influencent le plus les prévisions.

L'utilisation de techniques comme SHAP (SHapley Additive exPlanations) ou l'analyse des scores d'attention peut aider à comprendre les décisions du modèle en mettant en avant les contributions des entrées aux prédictions.

Lien avec ce projet

Chronos convertit les séries temporelles en séquences de tokens (quantifiés), puis applique un mécanisme d'attention pour identifier les relations temporelles clés. Cela permet :

- *D'intégrer des tendances complexes,*
- *De générer des intervalles de confiance pour évaluer l'incertitude,*
- *De s'adapter aux séries longues sans nécessiter d'ajustement manuel comme ARIMA.*

Chronos-Bolt-Base a été utilisé pour exploiter les capacités avancées des modèles préentraînés basés sur des transformateurs.

- *Prédictions probabilistes : Chronos génère des intervalles de confiance en plus des valeurs centrales, ce qui permet de quantifier l'incertitude des prévisions.*
- *Simplicité d'utilisation : Le modèle préentraîné offre des prédictions de haute qualité sans ajustement manuel complexe.*
- *Visualisations : Les prédictions médianes et les intervalles de confiance ont été visualisés pour mieux apprécier la fiabilité du modèle.*

AutoGluon pour la comparaison des modèles

AutoGluon a permis de comparer ARIMA et Chronos de manière rigoureuse en utilisant un pipeline d'entraînement automatique.

- *Les deux modèles ont été évalués sur le même ensemble de données.*
- *Un leaderboard a été généré pour identifier le meilleur modèle.*
- *Chronos-Bolt-Base s'est distingué avec des performances supérieures sur toutes les métriques considérées.*

Interprétabilité dans l'approche AutoGluon

AutoGluon étant un framework de machine learning automatisé, il sélectionne le meilleur modèle en fonction des performances globales, sans forcément privilégier l'interprétabilité.

Cependant, il est possible d'analyser les erreurs des modèles localement sur certaines périodes pour identifier les biais éventuels. Une comparaison des distributions d'erreurs d'ARIMA et Chronos peut donner des indications sur la fiabilité des prévisions selon les périodes.

Démarche d'optimisation

AutoGluon a comparé ARIMA et Chronos en optimisant leurs hyperparamètres. Chronos-Bolt-Base s'est distingué par ses performances supérieures.

Conclusion

La modélisation a permis de comparer deux approches :

- ARIMA, un modèle traditionnel bien adapté aux séries temporelles simples.
- Chronos, un modèle avancé exploitant des transformateurs préentraînés pour des prévisions probabilistes robustes.

Chronos s'est imposé comme le meilleur choix pour les séries temporelles complexes, avec des métriques de performance nettement supérieures. Bien que son interprétabilité soit plus limitée qu'ARIMA, l'analyse des scores d'attention et des distributions d'erreurs permet d'obtenir des explications sur les décisions du modèle. L'ajout de techniques comme SHAP pourrait également aider à mieux comprendre son fonctionnement.

Une synthèse des résultats

Synthèse des performances

Les modèles ARIMA et Chronos-Bolt-Base ont été comparés sur le dataset des ventes de camions en utilisant les métriques MAPE, MAE et MSE. Voici les résultats obtenus :

Modèle	MAPE (%)	MAE	MSE
ARIMA	25.6	150.2	30165.5
Chronos-Bolt-Base	6.1	40.6	2325.3


Analyse des performances

- **Précision** : Chronos-Bolt-Base surpasse nettement ARIMA sur toutes les métriques, avec un MAPE quatre fois inférieur et une réduction significative des erreurs absolues et quadratiques.
- **Stabilité** : Le faible MSE de Chronos indique une meilleure gestion des grandes erreurs, ce qui le rend plus fiable pour des prévisions stratégiques.
- **Robustesse** : Chronos est particulièrement adapté à des séries temporelles complexes avec des fluctuations irrégulières.


Visualisation des résultats

Les graphiques issus du notebook montrent clairement les différences entre les deux modèles :


- **Prédictions ARIMA** : Deux graphiques sont présentés pour illustrer les performances d'ARIMA :
 - a. Le graphique généré avec `auto_arima`, montrant une courbe pointillée qui reflète les ajustements aux fluctuations des séries temporelles.



- b. Un graphique issu d'AutoGluon, qui inclut les intervalles d'incertitude associés aux prédictions, bien que celles-ci apparaissent plus linéaires.



- **Prédictions Chronos** : Le second graphique montre que Chronos s'aligne beaucoup mieux sur les tendances des ventes et réagit efficacement aux variations saisonnières et aux pics. Les intervalles de confiance sont également bien intégrés, ce qui renforce la robustesse des prévisions.



Conclusion

Chronos-Bolt-Base représente une avancée majeure par rapport à ARIMA pour la prédiction de séries temporelles. Ses prévisions sont :

- *Plus précises, avec des erreurs minimales.*
- *Plus fiables, grâce à une gestion intégrée de l'incertitude.*
- *Mieux adaptées, aux séries complexes et aux fluctuations irrégulières.*

En conclusion, Chronos est le choix privilégié pour ce projet, offrant des résultats supérieurs et des capacités d'adaptation à des contextes variés.

L'analyse de la feature importance globale et locale du nouveau modèle

Limites de l'analyse de la feature importance

Dans le cadre de ce projet, l'analyse de la feature importance globale et locale n'a pas pu être réalisée pour les raisons suivantes :

Nature des modèles utilisés :

- **Chronos-Bolt-Base** : *Ce modèle est basé sur une architecture de transformateurs, qui n'offre pas directement une interprétation sous forme de feature importance. Contrairement aux modèles linéaires ou aux arbres de décision, Chronos fonctionne sur des représentations implicites des données, rendant difficile l'extraction d'une contribution explicite de chaque caractéristique temporelle.*
- **ARIMA** : *Ce modèle ne prend en compte qu'une seule série temporelle sans variables explicatives. Il ne fournit pas de mécanisme pour évaluer l'importance relative des données d'entrée.*

Absence de variables explicatives :

Le dataset utilisé ne contient qu'une seule série temporelle (Number_Trucks_Sold) sans variables additionnelles (comme des indicateurs économiques). En conséquence, il est impossible de déterminer l'influence relative d'autres facteurs potentiels.

Focus sur la prédiction :

L'objectif principal du projet est de produire des prédictions fiables des ventes de camions, et non de fournir une explication détaillée des contributions des caractéristiques.

Alternative : Analyse des performances globales et locales

Bien que l'analyse de la feature importance ne soit pas faisable, une évaluation approfondie des performances des modèles a permis de tirer des conclusions pertinentes :

Performances globales

- **Chronos-Bolt-Base** : Le modèle montre une forte capacité à capter les tendances générales et les variations saisonnières. Ses faibles erreurs globales (MAPE : 6,1 %, MAE : 40,6) indiquent qu'il utilise efficacement les données temporelles pour produire des prédictions précises.
- **ARIMA** : Bien que performant sur des séries temporelles simples, ARIMA montre des limites face aux variations complexes (MAPE : 12,39 %, MAE : 100,7).

Performances locales

- L'observation des erreurs de prédiction a révélé que Chronos réagit bien aux fluctuations soudaines, en capturant les pics et les creux des séries temporelles.
- Les graphiques de prédictions montrent que Chronos s'adapte mieux aux changements locaux par rapport à ARIMA, qui a tendance à lisser les variations abruptes.

Conclusion

L'absence de feature importance explicite dans ce projet ne constitue pas une limitation majeure. Les performances globales et locales des modèles, particulièrement celles de Chronos-Bolt-Base, fournissent des preuves solides de leur capacité à exploiter efficacement les données temporelles. En mettant l'accent sur la fiabilité et la précision des prédictions, le projet répond pleinement à ses objectifs sans nécessiter une analyse classique de la feature importance.

Les limites et les améliorations possibles

Les limites de l'approche actuelle

Bien que les résultats obtenus soient satisfaisants, l'approche actuelle présente plusieurs limites :

Absence de variables explicatives :

Le dataset utilisé se limite aux ventes mensuelles de camions, sans intégrer de données supplémentaires comme des indicateurs économiques (PIB, taux d'intérêt), climatiques ou sectoriels.

Cette absence limite la capacité des modèles à capturer des influences externes, ce qui pourrait réduire la précision des prédictions dans des contextes réels.

Interprétabilité des modèles :

Bien que Chronos-Bolt-Base soit performant, il manque d'interprétabilité directe. Contrairement à des modèles plus simples comme les arbres de décision, il n'est pas possible d'identifier précisément l'impact des données temporelles sur les prédictions.

Données synthétiques :

Le dataset est synthétique, ce qui signifie qu'il ne contient pas d'anomalies ou de bruit généralement présents dans des données réelles. Cela limite la validité des résultats dans des contextes opérationnels réels.

Améliorations possibles

Pour améliorer la précision et l'interprétabilité des prédictions, plusieurs axes d'amélioration sont envisageables :

Enrichissement du dataset :

Intégrer des données provenant de sources réelles afin de tester la robustesse des modèles face à des anomalies ou à des perturbations.

Optimisation des hyperparamètres :

Approfondir l'optimisation des hyperparamètres des modèles Chronos à l'aide de grilles de recherche ou d'algorithmes bayésiens pour maximiser leur performance.

Conclusion

Bien que l'approche actuelle ait permis d'obtenir des résultats convaincants, ces axes d'amélioration offrent des perspectives prometteuses pour renforcer la précision et l'interprétabilité des prédictions.

Références bibliographiques

- Box, G. E. P., & Jenkins, G. M. (1970). *Time Series Analysis: Forecasting and Control*. Holden-Day.
- Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.).
- Zhang, H., et al. (2024). An Overview of Recent Advances in Time Series Forecasting. arXiv preprint arXiv:2403.07815. [Disponible ici](#)
- Documentation officielle d'AutoGluon : <https://auto.gluon.ai>
- Documentation officielle de Chronos : <https://intel.github.io/neural-compressor>